Projeto 01 - Prevendo Consumo de Energia de Carros Elétricos

Descrição e Introdução do Problema de Negócio

Utilizando os dados do dataset, documentado no arquivo readme_projeto01.pdf, temos como objetivo prever o consumo de energia elétrica dos modelo da base e identificar insights importantes a possíveis oportunidades de melhoria.

```
# Pacotes utilizados
  library(readxl)
  library(thinkr)
  library(usefun)
  library(Amelia)
```

Carregando os dados e Ajustando o Dataset

```
# Carregando e Ajustando o Dataset
  getwd()
  ?read_xlsx

  dadosv00 <- read_xlsx('dados/fev_dataset.xlsx', na = 'NaN')

  View(dadosv00)
  dim(dadosv00)
  str(dadosv00)
```

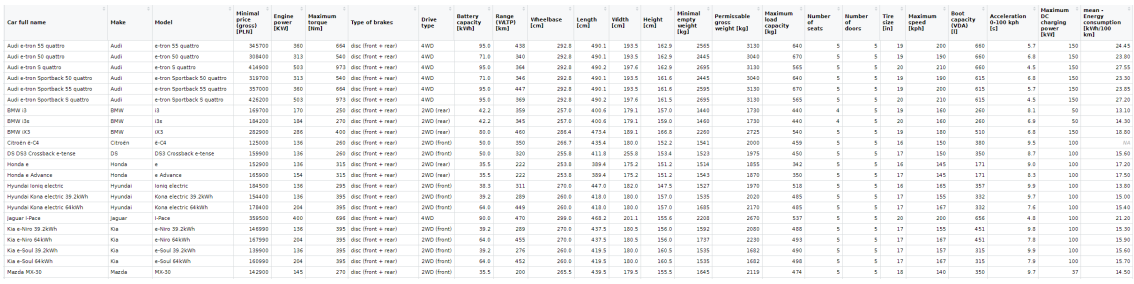

Car full name	Make	Model	Minimal price (gross) [PLN]	Engine power [KW]	Maximum torque [Nm]	Type of brakes	Drive type	Battery capacity [kWh]	Range (WLTP) [km]	Wheelbase [cm]	Length [cm]	Width [cm]	Height [cm]	Minimal empty weight [kg]	Permissable gross weight [kg]	Maximum load capacity [kg]	Number of seats	Number of doors	Tire size [in]	Maximum speed [kph]	Boot capacity (VDA) [l]	Acceleration 0-100 kph [s]	Maximum DC charging power [kW]	mean - Energy consumption [kWh/100 km]
Audi e-tron 55 quattro	Audi	e-tron 55 quattro	345700	360	664	disc (front + rear)	4WD	95.0	438	292.8	490.1	193.5	162.9	2565	3130	640	5	5	19	200	660	5.7	150	24.45
Audi e-tron 50 quattro	Audi	e-tron 50 quattro	308400	313	540	disc (front + rear)	4WD	71.0	340	292.8	490.1	193.5	162.9	2445	3040	670	5	5	19	190	660	6.8	150	23.80
Audi e-tron S quattro	Audi	e-tron S quattro	414900	503	973	disc (front + rear)	4WD	95.0	364	292.8	490.2	197.6	162.9	2695	3130	565	5	5	20	210	660	4.5	150	27.55
Audi e-tron Sportback 50 quattro	Audi	e-tron Sportback 50 quattro	319700	313	540	disc (front + rear)	4WD	71.0	346	292.8	490.1	193.5	161.6	2445	3040	640	5	5	19	190	615	6.8	150	23.30
Audi e-tron Sportback 55 quattro	Audi	e-tron Sportback 55 quattro	357000	360	664	disc (front + rear)	4WD	95.0	447	292.8	490.1	193.5	161.6	2595	3130	670	5	5	19	200	615	5.7	150	23.85
Audi e-tron Sportback S quattro	Audi	e-tron Sportback S quattro	426200	503	973	disc (front + rear)	4WD	95.0	369	292.8	490.2	197.6	161.5	2695	3130	565	5	5	20	210	615	4.5	150	27.20
BMW i3	BMW	i3	169700	170	250	disc (front + rear)	2WD (rear)	42.2	359	257.0	400.6	179.1	157.0	1440	1730	440	4	5	19	160	260	8.1	50	13.10
BMW i3s	BMW	i3s	184200	184	270	disc (front + rear)	2WD (rear)	42.2	345	257.0	400.6	179.1	159.0	1460	1730	440	4	5	20	160	260	6.9	50	14.30
BMW iX3	BMW	iX3	282900	286	400	disc (front + rear)	2WD (rear)	80.0	460	286.4	473.4	189.1	166.6	2260	2725	540	5	5	19	180	510	6.8	150	18.80
Citroën e-C4	Citroën	e-C4	125000	136	260	disc (front + rear)	2WD (front)	50.0	350	266.7	435.4	180.0	152.2	1541	2000	459	5	5	18	150	380	9.5	100	na
DS DS3 Crossback e-tense	DS	DS3 Crossback e-tense	159900	136	260	disc (front + rear)	2WD (front)	50.0	320	255.8	411.8	255.8	153.4	1523	1975	450	5	5	17	150	350	8.7	100	15.60
Honda e	Honda	e	152900	136	315	disc (front + rear)	2WD (rear)	35.5	222	253.8	389.4	175.2	151.2	1514	1855	342	5	5	16	145	171	9.0	100	17.20
Honda e Advance	Honda	e Advance	165900	154	315	disc (front + rear)	2WD (rear)	35.5	222	253.8	389.4	175.2	151.2	1543	1870	350	5	5	17	145	171	8.3	100	17.50
Hyundai Ioniq electric	Hyundai	Ioniq electric	184500	136	295	disc (front + rear)	2WD (front)	38.3	311	270.0	447.0	182.0	147.5	1527	1970	518	5	5	16	165	357	9.9	100	13.80
Hyundai Kona electric 39.2kWh	Hyundai	Kona electric 39.2kWh	154400	136	395	disc (front + rear)	2WD (front)	39.2	289	260.0	418.0	180.0	157.0	1535	2020	485	5	5	17	155	332	9.7	100	15.00
Hyundai Kona electric 64kWh	Hyundai	Kona electric 64kWh	178400	204	395	disc (front + rear)	2WD (front)	64.0	449	260.0	418.0	180.0	157.0	1685	2170	485	5	5	17	167	332	7.6	100	15.40
Jaguar I-Pace	Jaguar	I-Pace	359500	400	696	disc (front + rear)	4WD	90.0	470	299.0	468.2	201.1	155.6	2208	2670	537	5	5	20	200	656	4.8	100	21.20
Kia e-Niro 39.2kWh	Kia	e-Niro 39.2kWh	149990	136	395	disc (front + rear)	2WD (front)	39.2	289	270.0	437.5	180.5	156.0	1592	2080	488	5	5	17	155	451	9.8	100	15.30
Kia e-Niro 64kWh	Kia	e-Niro 64kWh	167990	204	395	disc (front + rear)	2WD (front)	64.0	455	270.0	437.5	180.5	156.0	1737	2230	493	5	5	17	167	451	7.8	100	15.90
Kia e-Soul 39.2kWh	Kia	e-Soul 39.2kWh	139900	136	395	disc (front + rear)	2WD (front)	39.2	276	260.0	419.5	180.0	160.5	1535	1682	490	5	5	17	157	315	9.9	100	15.60
Kia e-Soul 64kWh	Kia	e-Soul 64kWh	160990	204	395	disc (front + rear)	2WD (front)	64.0	452	260.0	419.5	180.0	160.5	1535	1682	498	5	5	17	167	315	7.9	100	15.70
Mazda MX-30	Mazda	MX-30	142900	145	270	disc (front + rear)	2WD (front)	35.5	200	265.5	439.5	179.5	155.5	1645	2119	474	5	5	18	140	350	9.7	37	14.50

```
>   str(dadosv00)
tibble [53 × 25] (S3: tbl_df/tbl/data.frame)
 $ Car full name                    : chr [1:53] "Audi e-tron 55 quattro" "Audi e-tron 50 quattro" "Audi e-tron S quattro" "Audi e-tron Sportback 50 quattro" ...
 $ Make                             : chr [1:53] "Audi" "Audi" "Audi" "Audi" ...
 $ Model                            : chr [1:53] "e-tron 55 quattro" "e-tron 50 quattro" "e-tron S quattro" "e-tron Sportback 50 quattro" ...
 $ Minimal price (gross) [PLN]      : num [1:53] 345700 308400 414900 319700 357000 ...
 $ Engine power [KW]                : num [1:53] 360 313 503 313 360 503 170 184 286 136 ...
 $ Maximum torque [Nm]              : num [1:53] 664 540 973 540 664 973 250 270 400 260 ...
 $ Type of brakes                   : chr [1:53] "disc (front + rear)" "disc (front + rear)" "disc (front + rear)" "disc (front + rear)" ...
 $ Drive type                       : chr [1:53] "4WD" "4WD" "4WD" "4WD" ...
 $ Battery capacity [kWh]           : num [1:53] 95 71 95 71 95 95 42.2 42.2 80 50 ...
 $ Range (WLTP) [km]                : num [1:53] 438 340 364 346 447 369 359 345 460 350 ...
 $ Wheelbase [cm]                   : num [1:53] 293 293 293 293 293 ...
 $ Length [cm]                      : num [1:53] 490 490 490 490 490 ...
 $ Width [cm]                       : num [1:53] 194 194 198 194 194 ...
 $ Height [cm]                      : num [1:53] 163 163 163 162 162 ...
 $ Minimal empty weight [kg]        : num [1:53] 2565 2445 2695 2445 2595 ...
 $ Permissable gross weight [kg]    : num [1:53] 3130 3040 3130 3040 3130 ...
 $ Maximum load capacity [kg]       : num [1:53] 640 670 565 640 670 565 440 440 540 459 ...
 $ Number of seats                  : num [1:53] 5 5 5 5 5 5 4 4 5 5 ...
 $ Number of doors                  : num [1:53] 5 5 5 5 5 5 5 5 5 5 ...
 $ Tire size [in]                   : num [1:53] 19 19 20 19 19 20 19 20 19 16 ...
 $ Maximum speed [kph]              : num [1:53] 200 190 210 190 200 210 160 160 180 150 ...
 $ Boot capacity (VDA) [l]          : num [1:53] 660 660 660 615 615 615 260 260 510 380 ...
 $ Acceleration 0-100 kph [s]       : num [1:53] 5.7 6.8 4.5 6.8 5.7 4.5 8.1 6.9 6.8 9.5 ...
 $ Maximum DC charging power [kW]   : num [1:53] 150 150 150 150 150 150 50 50 150 100 ...
 $ mean - Energy consumption [kWh/100 km]: num [1:53] 24.4 23.8 27.6 23.3 23.9 ...
>
```

```
# Convertendo o objeto para DataFrame
  dadosv00 <- as.data.frame(dadosv00)
```

```
# Verificando Dados NaN
  summary(is.na(dadosv00))
  colSums(is.na(dadosv00))
  missmap(dadosv00)
```

```
>   summary(is.na(dadosv00))
 Car full name      Make           Model         Minimal price (gross) [PLN] Engine power [KW]
 Mode :logical   Mode :logical   Mode :logical   Mode :logical               Mode :logical
 FALSE:53        FALSE:53        FALSE:53        FALSE:53                    FALSE:53

 Maximum torque [Nm] Type of brakes  Drive type      Battery capacity [kWh] Range (WLTP) [km]
 Mode :logical       Mode :logical   Mode :logical   Mode :logical          Mode :logical
 FALSE:53            FALSE:52        FALSE:53        FALSE:53               FALSE:53
                     TRUE :1
 Wheelbase [cm]  Length [cm]     Width [cm]      Height [cm]     Minimal empty weight [kg]
 Mode :logical   Mode :logical   Mode :logical   Mode :logical   Mode :logical
 FALSE:53        FALSE:53        FALSE:53        FALSE:53        FALSE:53

 Permissable gross weight [kg] Maximum load capacity [kg] Number of seats Number of doors
 Mode :logical                 Mode :logical              Mode :logical   Mode :logical
 FALSE:45                      FALSE:45                   FALSE:53        FALSE:53
 TRUE :8                       TRUE :8
 Tire size [in]  Maximum speed [kph] Boot capacity (VDA) [l] Acceleration 0-100 kph [s]
 Mode :logical   Mode :logical       Mode :logical           Mode :logical
 FALSE:53        FALSE:53            FALSE:52                FALSE:50
                                     TRUE :1                 TRUE :3
 Maximum DC charging power [kW] mean - Energy consumption [kWh/100 km]
 Mode :logical                  Mode :logical
 FALSE:53                       FALSE:44
                                TRUE :9
```

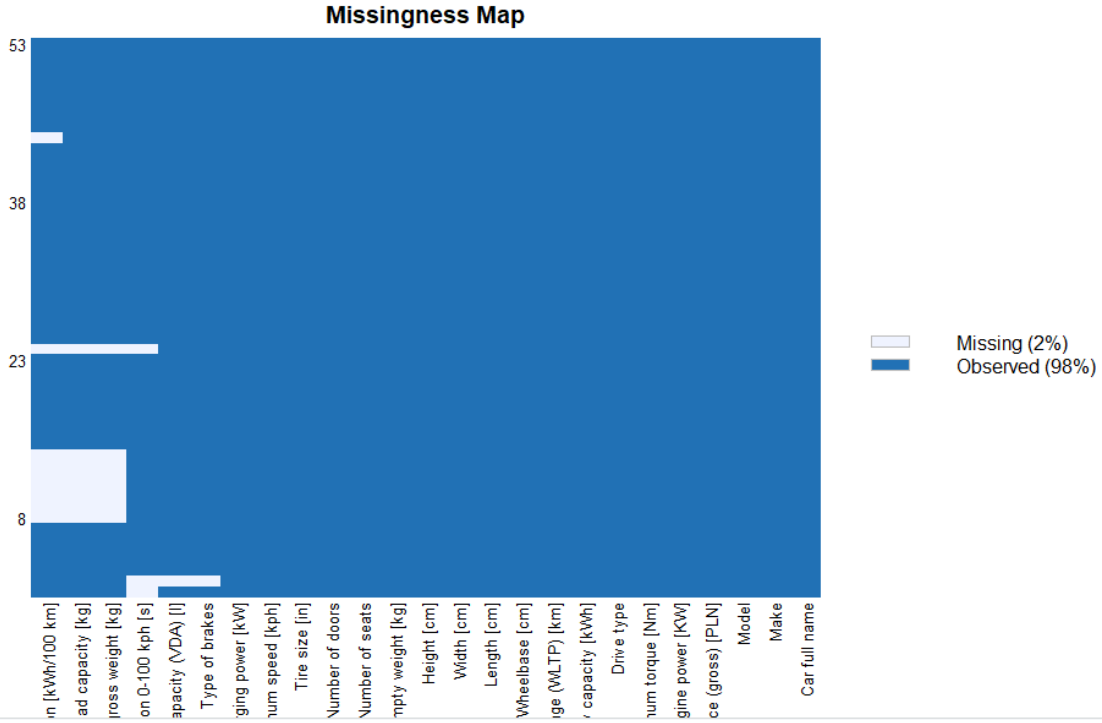

Temos algumas linhas vazias no dataset, especificamente na coluna Média de Consumo, sendo esta nossa variável resposta. Vamos apenas excluir esses dados incompletos para não tendenciar o erro de previsão durante a nossa modelagem preditiva. Poderíamos ter aplicado alguma técnica de imputação, mas neste primeiro momento vamos processeguir apenas sem os dados imcompletos e verificar quais resultados podemos alcançar.

```
# Eliminando os dados Na
  dadosv01 <- na.omit(dadosv00)
```

```
summary(is.na(dadosv01))
colSums(is.na(dadosv01))
missmap(dadosv01)
```

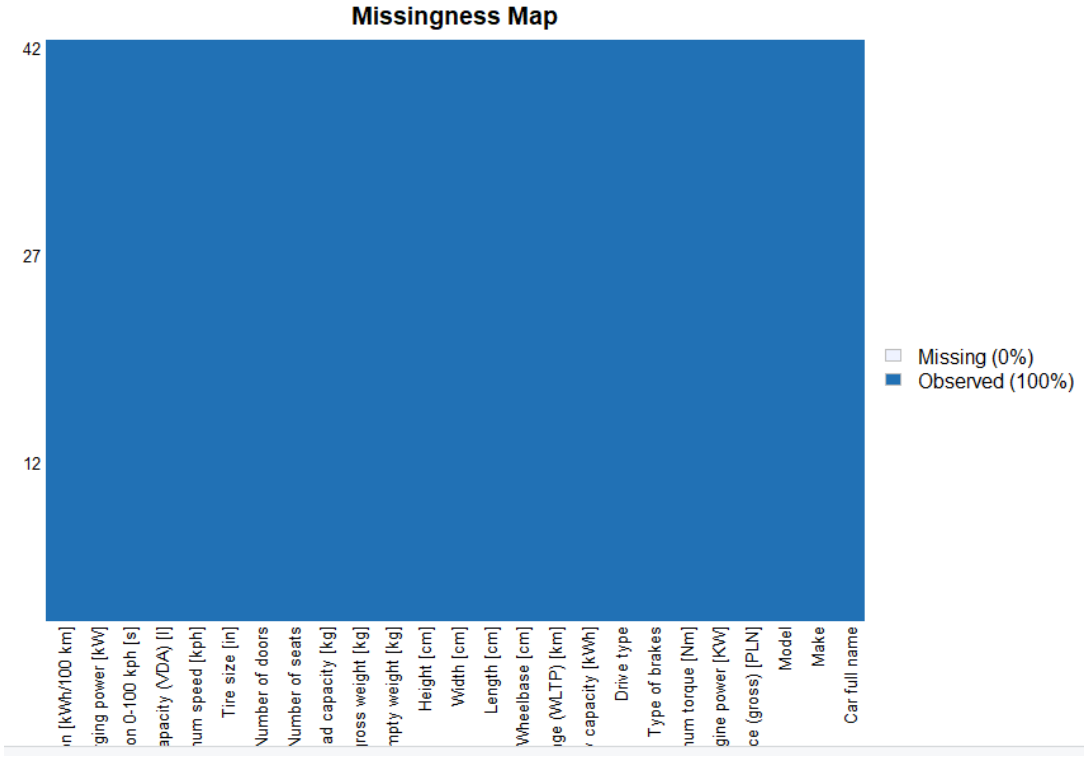


```
# Renomeando as Colunas
  nomesCol <- c('Carro', 'Fabricante', 'Modelo', 'PrecoMin', 'Potencia',
                'TorqMax', 'Freios','Cambio', 'CapBat', 'Autonomia',
                'DistEixos', 'Comprimento', 'Largura', 'Altura', 'PesoVazio',
                'PesoCheio', 'CapMax', 'NumAssentos', 'NumeroPortas',
                'TamPneu','VelMax', 'BootCap', 'Acc', 'CapMaxBat',
                'ConsMedio')
  colnames(dadosv01) <- nomesCol
  View(dadosv01)
```

Carro	Fabricante	Modelo	PrecoMin	Potencia	TorqMax	Freios	Can
Audi e-tron 55 quattro	Audi	e-tron 55 quattro	345700	360	664	disc (front + rear)	4WI
Audi e-tron 50 quattro	Audi	e-tron 50 quattro	308400	313	540	disc (front + rear)	4WI
Audi e-tron S quattro	Audi	e-tron S quattro	414900	503	973	disc (front + rear)	4WI
Audi e-tron Sportback 50 quattro	Audi	e-tron Sportback 50 quattro	319700	313	540	disc (front + rear)	4WI
Audi e-tron Sportback 55 quattro	Audi	e-tron Sportback 55 quattro	357000	360	664	disc (front + rear)	4WI
Audi e-tron Sportback S quattro	Audi	e-tron Sportback S quattro	426200	503	973	disc (front + rear)	4WI
BMW i3	BMW	i3	169700	170	250	disc (front + rear)	2WI
BMW i3s	BMW	i3s	184200	184	270	disc (front + rear)	2WI

Realizando Label Encoding das Variáveis Categóricas

Como pretendemos criar um modelo de regressão, precisamos identificar quais variáveis categoricas vamos transformar em numericas.

Temos como Variáveis Categoricas: Carro, Fabricante, Modelo , Freios e Cambio. Vamos descartar Modelo e Carro, pois não são pertinentes a análise da variável resposta, conforme orientado pela área de negócio.

```
# Realizando Label Encoding das Variáveis Categóricas

  dadosv01$Fabricante <- as.numeric(as.factor(dadosv01$Fabricante))

  dadosv01$Freios <- as.numeric(as.factor(dadosv01$Freios))

  dadosv01$Cambio <- as.numeric(as.factor(dadosv01$Cambio))

  str(dadosv01)
```

Dicionário da Variável Fabricante

- Audi = 1
- BMW = 2
- Citroen = 3
- DS = 4
- Honda = 5
- Hyundai = 6
- Jaguar = 7
- Kia = 8
- Mazda = 9
- Mercedes-Benz = 10
- Mini = 11
- Nissan = 12
- Opel = 13
- Peugeot = 14
- Porshe = 15
- Renault = 16
- Skoda = 17
- Smart = 18
- Volkswagen = 19

Dicionário da Variável Fabricante

- Freio a Disco nas 4 rodas = 1
- Freio a Disco na Dianteira e Tambor na traseira = 2

Dicionário da Variável Fabricante

- 4WD = 3
- 2WD(rear) = 2
- 2WD(front) = 1

Salvando Dataset Modificado em Disco

```
file = 'dados/dados_ajustados.csv'
  save_df_to_file(dadosv01, file = file)
```

Neste momento estamos prontos para iniciar nossas análises exploratórias e preparar nosso dataset para construção dos modelos de Machine Learning.

Análise Exploratória

```
# Pacotes

  library(kim)
  library(plotly)
  library(ggplot2)
  library(dplyr)
  library(corrplot)
  library(GGally)
  library(gridExtra)
```

```
# Verificando e ajustando os tipos de variáveis

  dados <- as.data.frame(read_csv(name = 'dados_ajustados', head = TRUE,
                                  dirname = 'dados' ))

  dados <- dados[, -1]
  dados$Fabricante <- as.factor(dados$Fabricante)
  dados$Freios <- as.factor(dados$Freios)
  dados$Cambio <- as.factor(dados$Cambio)

  str(dados)
  View(dados)
```

```
'data.frame':   42 obs. of  25 variables:
 $ Carro       : chr  "Audi e-tron 55 quattro" "Audi e-tron 50 quattro" "
ttro" "Audi e-tron Sportback 50 quattro" ...
 $ Fabricante  : Factor w/ 19 levels "1","2","3","4",..: 1 1 1 1 1 1 2 2
 $ Modelo      : chr  "e-tron 55 quattro" "e-tron 50 quattro" "e-tron S q
portback 50 quattro" ...
 $ PrecoMin    : int  345700 308400 414900 319700 357000 426200 169700 18
0 ...
 $ Potencia    : int  360 313 503 313 360 503 170 184 286 136 ...
 $ TorqMax     : int  664 540 973 540 664 973 250 270 400 260 ...
 $ Freios      : Factor w/ 2 levels "1","2": 1 1 1 1 1 1 1 1 1 1 ...
 $ Cambio      : Factor w/ 3 levels "1","2","3": 3 3 3 3 3 3 2 2 2 1 ...
 $ CapBat      : num  95 71 95 71 95 95 42.2 42.2 80 50 ...
 $ Autonomia   : int  438 340 364 346 447 369 359 345 460 320 ...
 $ DistEixos   : num  293 293 293 293 293 ...
 $ Comprimento : num  490 490 490 490 490 ...
 $ Largura     : num  194 194 198 194 194 ...
 $ Altura      : num  163 163 163 162 162 ...
 $ PesoVazio   : int  2565 2445 2695 2445 2595 2695 1440 1460 2260 1523 .
 $ PesoCheio   : int  3130 3040 3130 3040 3130 3130 1730 1730 2725 1975 .
 $ CapMax      : int  640 670 565 640 670 565 440 440 540 450 ...
 $ NumAssentos : int  5 5 5 5 5 5 4 4 5 5 ...
 $ NumeroPortas: int  5 5 5 5 5 5 5 5 5 5 ...
 $ TamPneu     : int  19 19 20 19 19 20 19 20 19 17 ...
 $ VelMax      : int  200 190 210 190 200 210 160 160 180 150 ...
 $ BootCap     : int  660 660 660 615 615 615 260 260 510 350 ...
 $ Acc         : num  5.7 6.8 4.5 6.8 5.7 4.5 8.1 6.9 6.8 8.7 ...
 $ CapMaxBat   : int  150 150 150 150 150 150 50 50 150 100 ...
 $ ConsMedio   : num  24.4 23.8 27.6 23.3 23.9 ...
```

Iniciamos nossa Análise Exploratória analisando um sumário geral dos dados, porém como temos muitas variáveis, é mais pratico analisarmos de forma separada Variáveis Numéricas, Categóricas e a Variável Resposta.

```
# Análise Exploratória dos Dados

  summary(dados)

    # Podemos reparar que a Média e a Mediana possuem valores próximos em todas
    # as variáveis numéricas, o que nos indica uma possível distribuição normal.

  # Vamos separar as Variáveis em Numérias, Categoricas e Resposta para
  # analisarmos de forma separada.

    VarNum <- dados %>% select(c(4:6), c(9:24))
    VarCat <- dados %>% select(c(1:3), c(7:8))
    VarResp <- dados$ConsMedio
```

Análise da Variável Resposta

```
# Variável Resposta

    summary(VarResp) # Min. 13.10 / 1st Qu.15.60 / Median 16.88 / Mean 18.61
                     #  3rd Qu. 22.94 / Max. 27.55

    diff(range(VarResp)) # 14.45

    sd(VarResp) # 4.134293

    var(VarResp) # 17.09238


    hist(VarResp, main = 'Distribuição do Consumo Médio em Carros Elétricos',
       xlab = 'Consumo de Energia [kW/h]')
```

```
 Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
13.10   15.60   16.88   18.61   22.94   27.55
```

Logo de início percebemos que a mediana é inferior a Média dos Dados, o que mostra que nossa curva está deslocada a direita (região caudal), provavelmente com um Skewness positivo.

```
>     skewness(VarResp)
[1] 0.7857014
```

A distância máxima do range é de 14,45, conforme podemos verificar:

```
>     diff(range(VarResp)) # 14.45
[1] 14.45
```

O que nos mostra que a maior diferença entre os modelos não ultrapassa 15 kW/h em consumo.

Nosso desvio padrão é de 4,13 kW/h e a variância de 17,09.

```
>     sd(VarResp) # 4.134293
[1] 4.134293
>
>     var(VarResp) # 17.09238
[1] 17.09238
```

Podemos ver a questão do Skewness no histograma abaixo:

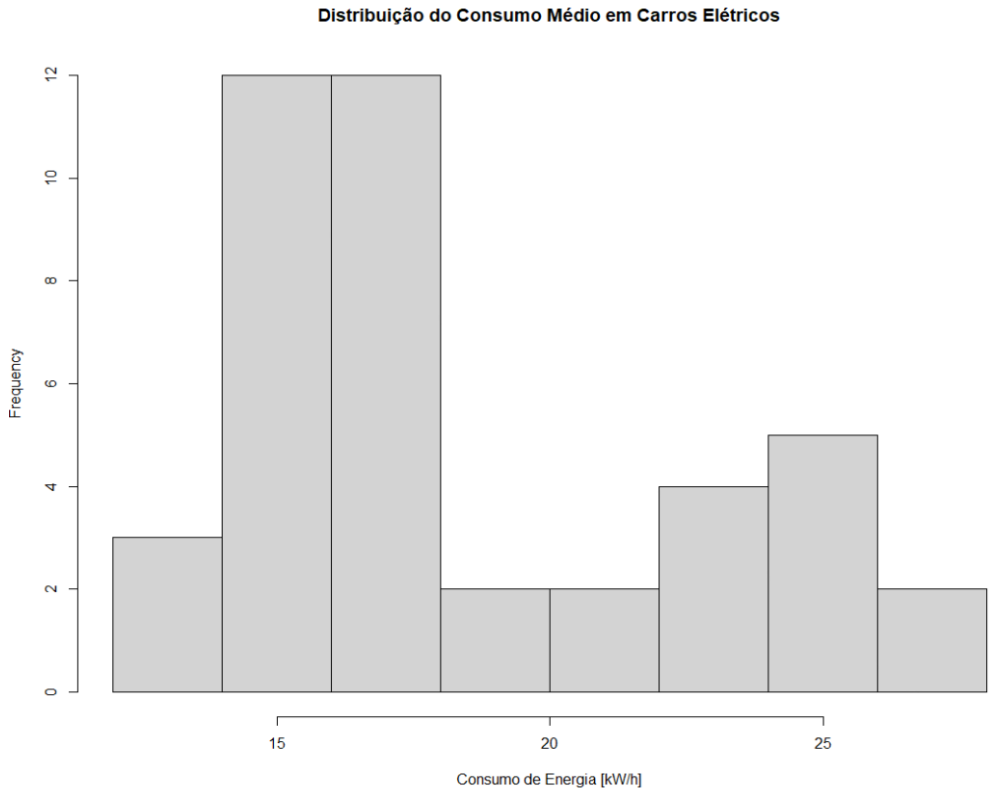

Temos alguns dados discrepantes, com valores muito acima da mediana dos dados, talvez um outlier, o que podemos observar com a construção de um boxplot.

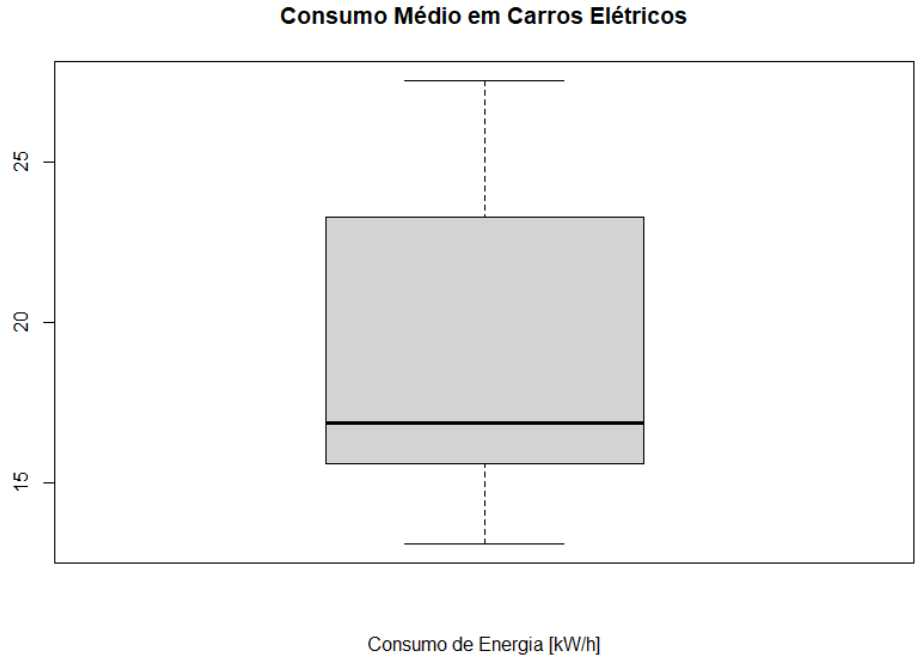

Observamos que não temos dados outliers, mantendo assim os dados com um padrão razoável para serem analisados.

Não podemos afirmar que temos uma distribuição normal nos dados, mas podemos realizar um teste de Shapiro e verificar se existe normalidade na distribuição dos dados.

- H0 → Consideramos que os dados são normalmente distribuidos
- H1 → Não podemos considerar que os dados são normalmente distribuídos
  - Se p-value > que 0.05 não podemos rejeitar H0
  - Se p-value < que 0.05 então rejeitamos H0.

```
shapiro.test(VarResp)
```

```
        Shapiro-Wilk normality test

data:  VarResp
W = 0.86663, p-value = 0.0001665
```

Podemos perceber que p-value é menor que 0.05, sendo assim, não podemos considerar que os dados da Variável resposta seguem uma distribuição Normal, ou seja, rejeitamos H0.

Análise das Variáveis Numéricas

Inicialmente, vamos verificar um resumo de cada variável:

```
summary(VarNum)
```

```
>   summary(VarNum)
    PrecoMin         Potencia        TorqMax          CapBat        Autonomia
 Min.   : 82050   Min.   : 82.0   Min.   : 160.0   Min.   :17.60   Min.   :148.0
 1st Qu.:140650   1st Qu.:136.0   1st Qu.: 260.0   1st Qu.:39.20   1st Qu.:279.2
 Median :166945   Median :184.0   Median : 317.5   Median :52.00   Median :352.5
 Mean   :235066   Mean   :237.7   Mean   : 425.2   Mean   :58.84   Mean   :351.7
 3rd Qu.:316875   3rd Qu.:313.0   3rd Qu.: 540.0   3rd Qu.:78.65   3rd Qu.:434.8
 Max.   :794000   Max.   :625.0   Max.   :1050.0   Max.   :95.00   Max.   :549.0
   DistEixos      Comprimento      Largura         Altura        PesoVazio      PesoCheio
 Min.   :187.3   Min.   :269.5   Min.   :164.5   Min.   :137.8   Min.   :1035   Min.   :1310
 1st Qu.:256.3   1st Qu.:406.6   1st Qu.:178.7   1st Qu.:151.2   1st Qu.:1516   1st Qu.:1882
 Median :270.0   Median :431.8   Median :180.2   Median :156.0   Median :1622   Median :2100
 Mean   :269.8   Mean   :433.5   Mean   :184.8   Mean   :155.0   Mean   :1821   Mean   :2268
 3rd Qu.:290.0   3rd Qu.:475.5   3rd Qu.:193.5   3rd Qu.:160.5   3rd Qu.:2249   3rd Qu.:2855
 Max.   :327.5   Max.   :496.3   Max.   :255.8   Max.   :190.0   Max.   :2695   Max.   :3130
     CapMax        NumAssentos     NumeroPortas     TamPneu          VelMax
 Min.   : 290.0   Min.   :2.000   Min.   :3.00   Min.   :14.00   Min.   :130.0
 1st Qu.: 440.0   1st Qu.:4.250   1st Qu.:5.00   1st Qu.:16.00   1st Qu.:146.2
 Median : 485.5   Median :5.000   Median :5.00   Median :17.00   Median :160.0
 Mean   : 510.5   Mean   :4.762   Mean   :4.81   Mean   :17.55   Mean   :169.5
 3rd Qu.: 565.0   3rd Qu.:5.000   3rd Qu.:5.00   3rd Qu.:19.00   3rd Qu.:187.5
 Max.   :1056.0   Max.   :8.000   Max.   :5.00   Max.   :21.00   Max.   :260.0
    BootCap           Acc            CapMaxBat
 Min.   :171.0   Min.   : 2.800   Min.   : 22.0
 1st Qu.:310.2   1st Qu.: 6.800   1st Qu.: 62.5
 Median :371.0   Median : 7.900   Median :100.0
 Mean   :404.3   Mean   : 7.893   Mean   :109.7
 3rd Qu.:497.0   3rd Qu.: 9.650   3rd Qu.:143.8
 Max.   :660.0   Max.   :13.100   Max.   :270.0
```

Vamos analisar de forma gráfica um multi-histograma:

```
# Multi-Hitogramas de cada Variável

     VarNum01 <- ggplot(VarNum) + geom_histogram(aes(x = PrecoMin))
```

```
VarNum02 <- ggplot(VarNum) + geom_histogram(aes(x = Potencia))
VarNum03 <- ggplot(VarNum) + geom_histogram(aes(x = TorqMax))
VarNum04 <- ggplot(VarNum) + geom_histogram(aes(x = CapBat))
VarNum05 <- ggplot(VarNum) + geom_histogram(aes(x = Autonomia))
VarNum06 <- ggplot(VarNum) + geom_histogram(aes(x = DistEixos))
VarNum07 <- ggplot(VarNum) + geom_histogram(aes(x = Comprimento))
VarNum08 <- ggplot(VarNum) + geom_histogram(aes(x = Largura))
VarNum09 <- ggplot(VarNum) + geom_histogram(aes(x = Altura))
VarNum10 <- ggplot(VarNum) + geom_histogram(aes(x = PesoVazio))
VarNum11 <- ggplot(VarNum) + geom_histogram(aes(x = PesoCheio))
VarNum12 <- ggplot(VarNum) + geom_histogram(aes(x = CapMax))
VarNum13 <- ggplot(VarNum) + geom_histogram(aes(x = NumAssentos))
VarNum14 <- ggplot(VarNum) + geom_histogram(aes(x = NumeroPortas))
VarNum15 <- ggplot(VarNum) + geom_histogram(aes(x = TamPneu))
VarNum16 <- ggplot(VarNum) + geom_histogram(aes(x = VelMax))
VarNum17 <- ggplot(VarNum) + geom_histogram(aes(x = BootCap))
VarNum18 <- ggplot(VarNum) + geom_histogram(aes(x = Acc))
VarNum19 <- ggplot(VarNum) + geom_histogram(aes(x = CapMaxBat))

grid.arrange(VarNum01, VarNum02, VarNum03, VarNum04, VarNum05,
             VarNum06, VarNum07, VarNum08, VarNum09, VarNum10,
             VarNum11, VarNum12, VarNum13, VarNum14, VarNum15,
             VarNum16, VarNum17, VarNum18,VarNum19)
```

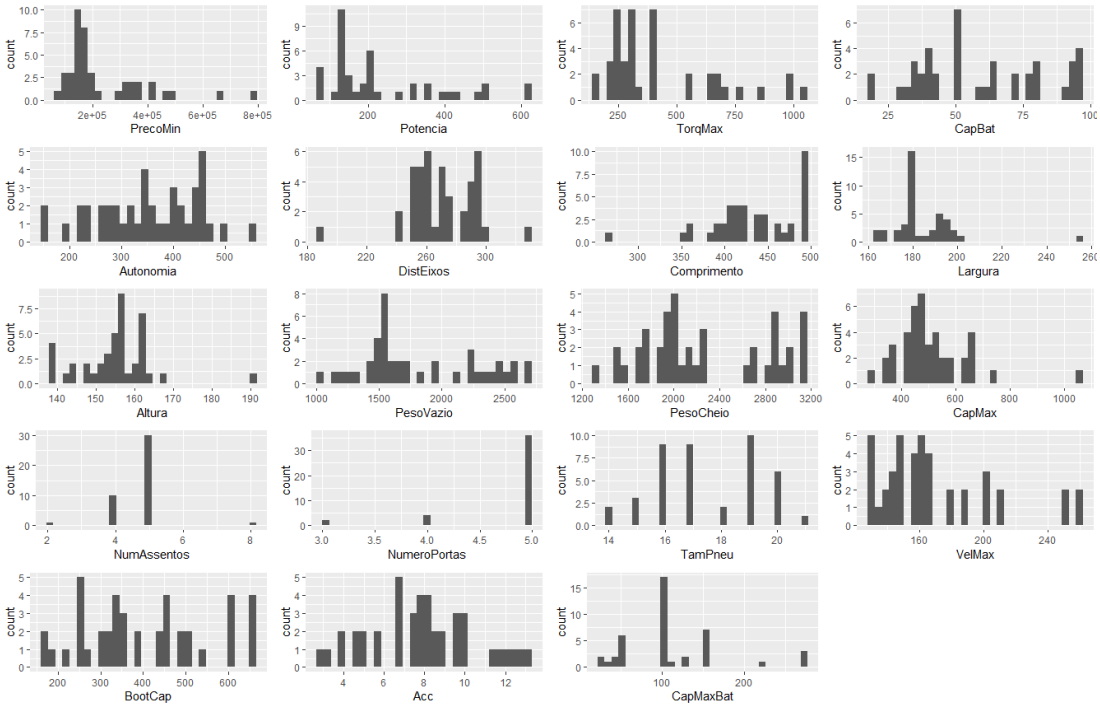

Percebemos que em nosso dataset temos carros de categorias diferentes, apesar de mesmo combustível propulsor, sendo assim um dataset misto, não condicionalnando a categoria dos veículos. Talvez seria interessante obtermos mais dados de veículos e categorizar os mesmos (etiquetar) para que possamos analisar de forma separada. Podemos corroborar com essa afirmação quando olhamos dados extremos em TorqMax, Potencia, PrecoMin, CapBat e VelMax.

Um outro ponto importante para nossa análise é identificar como as variáveis se relacionam entre si e entre elas e a variável resposta. Vamos realizar uma análise de Correlação a fim de identificar problemas de Multicolinearidade por exemplo.

```
# Análise de Multicolinearidade

      corrplot(cor(cbind(VarNum, VarResp)))
```

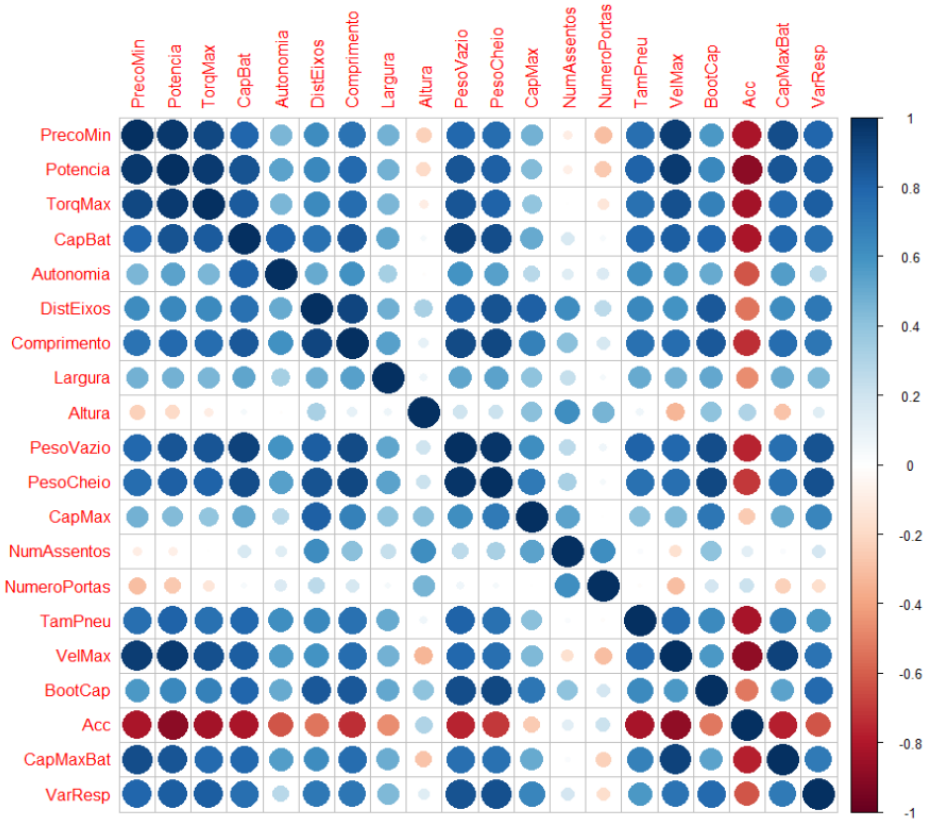

Podemos identificar aqui uma excessiva correlação entre diversas variáveis, o que possivelmente causa confusão durante nossa modelagem preditiva. Correlações como Peso/potencia, DistEixos/CapMax, são relativamente óbvias ao modelo de negócio. Porém observando a nossa Variável Resposta, podemos ver altas correlações com as variáveis, Preço, Potencia, TorqMax, CapBat, Peso Vazio, Pezo Cheio, BootCap e Acc. De qualquer forma, vamos utilizar um algoritmo de regressão linear para nos ajudar a melhor selecionar nossas variáveis.

Para melhor analisarmos a correlação entre as variáveis, vamos diagramar um gráfico multi variável.

```
# Scatterplots de Cada Variável Numérica Dependente e a Variável Resposta

      DadosIntResp <-dados %>% select(c(4:6), c(9:25))
      Multiplot <- function(DadosIntResp, mapping, method = "loess", ...){
        p <- ggplot(data = data, mapping = mapping) +
          geom_point()+
          geom_smooth(method = method, ...)
        p
      }
      ggpairs(DadosIntResp, lower = list(continous = Multiplot))
```

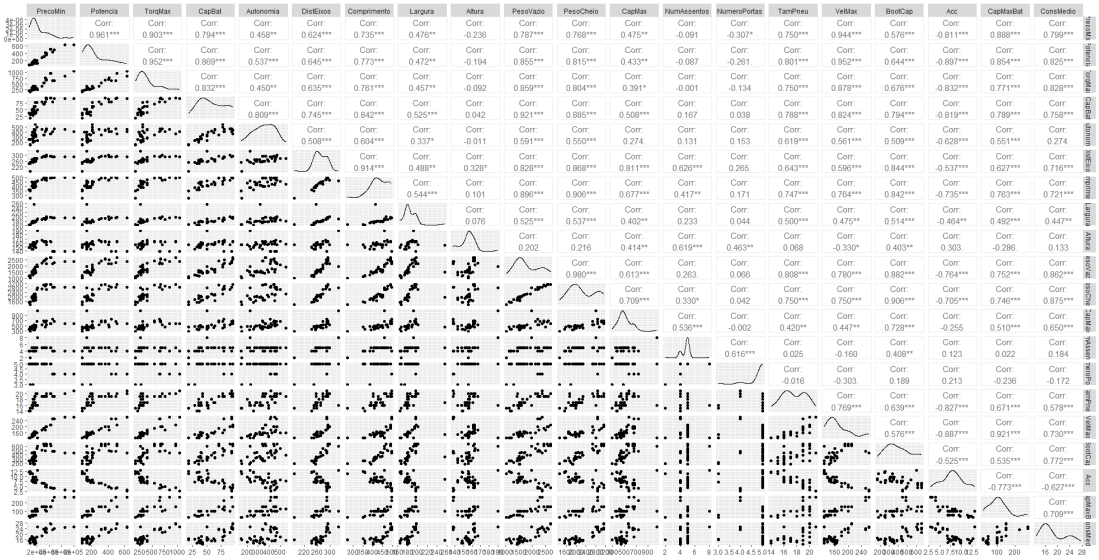

Análise de Variáveis Categóricas

Vamos ignorar o fabricante neste momento, pois aparentemente não parece relevante, visto que temos 19 fabricantes para 43 observações, o que não nos dá uma amostra razoável para analisar por esse angulo de visão.

Iniciamos então analisando as proporções de dados para cada fator das variáveis Freio e Cambio.

```
prop.table(table(VarCat$Freios))*100
prop.table(table(VarCat$Cambio))*100
```

```
> prop.table(table(VarCat$Freios))*100

       1        2
83.33333 16.66667
>     prop.table(table(VarCat$Cambio))*100

       1        2        3
47.61905 23.80952 28.57143
```

Percebemos q temos muito mais dados de carro com freios a disco nas quatro rodas que apenas disco frontal.

Também é possível perceber que temos um certo equilíbrio na variável de cambio, o que é melhor para nosso modelo preditivo.

Vamos analisar como é Consumo de Energia para cada tipo de variável, calculando a média para cada categoria.

```
media_por_tipo_de_freio = dados %>% group_by(Freios) %>%
      summarise(avg_consumo = mean(ConsMedio))

    media_por_tipo_de_tracao = dados %>% group_by(Cambio) %>%
      summarise(avg_consumo = mean(ConsMedio))

    barplot(media_por_tipo_de_freio$avg_consumo,
            names.arg = media_por_tipo_de_freio$Freios,
            main = 'Média de Consumo por Tipo de Freio')

    barplot(media_por_tipo_de_tracao$avg_consumo,
            names.arg = media_por_tipo_de_tracao$Cambio,
            main = 'Média de Consumo por Tipo de Tração')
```

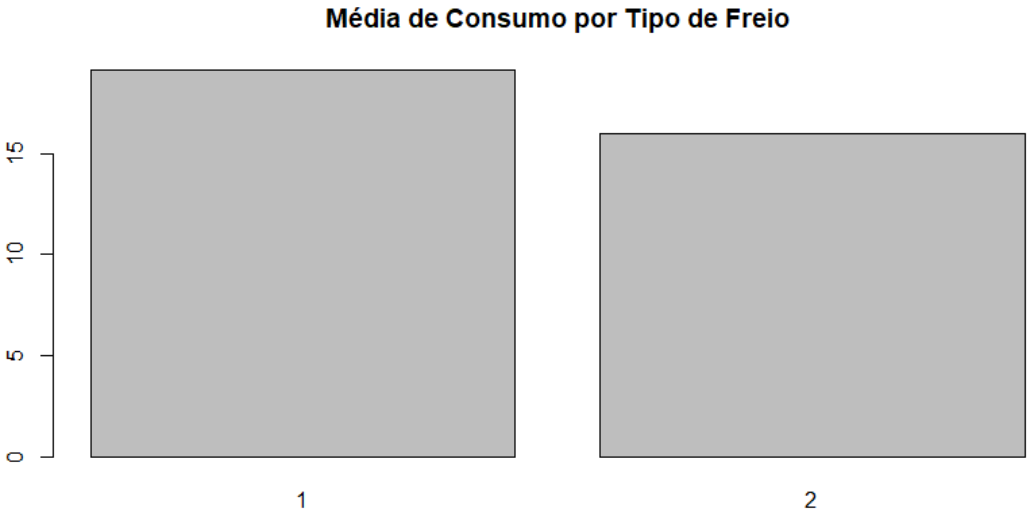

Podemos verificar claramente que carro que possuem frenagem frontal e traseira a disco, possuem maior consumo de energia por hora. Aqui não estamos vendo causalidade, apenas constatando o fato de que carros com essa característica em média consome mais energia elétrica.

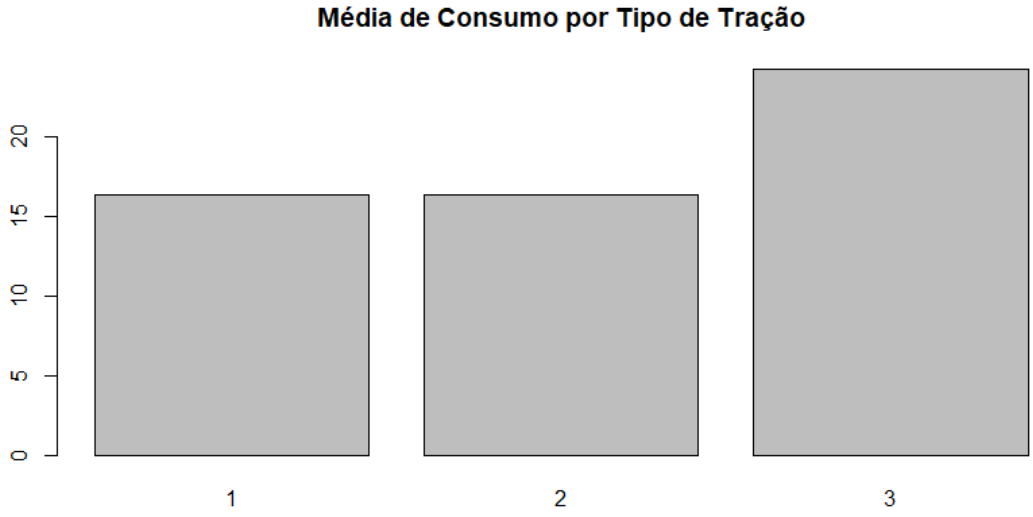

Nesta variável, percebemos que carros que possuem tração nas 4 rodas possuem um consumo de energia maior. Aqui é um fato diretamente relacionado a natureza do cambio 4WD, visto que se necessita admitir energia em 4 rodas para aplicar tração, consequentemente usa-se maior quantidade de energia que para apenas 2 rodas.

Porém uma fator descoberto é interessante, o consumo médio é muito próximo em carros com tração dianteira ou trazeira.

Finalizamos nossa Exporação dos Dados e estamos prontos para iniciar a etapa de Preparação para a construção do modelo preditivo e solução do problema de négocio definido.

Pre-Processamento dos Dados

Nesta etapa vamos aplicar Feature Selection e definir quais variáveis vamos levar em consideração para a construção do nosso Modelo Base. A regra aqui é encontrar uma boa eficiência na métrica do modelo, sendo ele o máis simples possível.

```
# Carregando Pacotes
  #
    library(dplyr)
    library(kim)
    library(caret)

  # Carregando o Dataset

    dados <- as.data.frame(read_csv(name = 'dados_ajustados', head = TRUE,
                                    dirname = 'dados' ))
    dim(dados)
    dados <- dados[, 5:26]
    dim(dados)
    str(dados)
    dados$Freios <- as.factor(dados$Freios)
    dados$Cambio <- as.factor(dados$Cambio)
    dados$NumAssentos <- as.factor(dados$NumAssentos)
    dados$NumeroPortas <- as.factor(dados$NumeroPortas)
    str(dados)
    View(dados)FeaturesLM <- lm(ConsMedio ~ .,
                  data = dados)
    summary(FeaturesLM)
```

Feature Selection

Vamos utilizar um modelo linear simples com todas as variáveis para determinar quais são as variáveis mais significantes para explicar nossa variável alvo.

```
    FeaturesLM <- lm(ConsMedio ~ .,
                   data = dados)
    summary(FeaturesLM)
```

```
Call:
lm(formula = ConsMedio ~ ., data = dados)

Residuals:
    Min      1Q  Median      3Q     Max
-1.2542 -0.3364  0.0000  0.3086  1.1067

Coefficients:
                Estimate Std. Error t value Pr(>|t|)
(Intercept)    6.217e+01  1.628e+01   3.820  0.00151 **
PrecoMin       4.431e-06  6.499e-06   0.682  0.50506
Potencia       6.931e-03  1.138e-02   0.609  0.55091
TorqMax       -1.455e-03  4.577e-03  -0.318  0.75469
Freios2       -2.390e-02  1.318e+00  -0.018  0.98576
Cambio2        3.808e+00  1.278e+00   2.981  0.00883 **
Cambio3        5.277e+00  2.220e+00   2.378  0.03024 *
CapBat         8.619e-02  6.756e-02   1.276  0.22028
Autonomia     -1.652e-02  7.108e-03  -2.324  0.03364 *
DistEixos     -2.622e-01  1.198e-01  -2.188  0.04384 *
Comprimento    2.159e-02  4.208e-02   0.513  0.61499
Largura       -1.965e-02  1.428e-02  -1.377  0.18762
Altura         4.024e-02  7.665e-02   0.525  0.60674
PesoVazio      2.635e-03  7.014e-03   0.376  0.71209
PesoCheio     -2.122e-03  3.314e-03  -0.640  0.53114
CapMax        -3.181e-03  7.710e-03  -0.413  0.68541
NumAssentos4   1.823e+01  7.864e+00   2.318  0.03402 *
NumAssentos5   2.157e+01  9.505e+00   2.269  0.03748 *
NumAssentos8   4.114e+01  1.861e+01   2.211  0.04196 *
NumeroPortas4  1.676e+00  2.917e+00   0.575  0.57353
NumeroPortas5 -4.450e+00  2.216e+00  -2.008  0.06180 .
TamPneu       -7.817e-01  2.807e-01  -2.785  0.01325 *
VelMax         1.474e-02  7.138e-02   0.207  0.83896
BootCap        2.489e-02  8.726e-03   2.852  0.01153 *
Acc           -2.294e-01  3.102e-01  -0.739  0.47040
CapMaxBat     -8.928e-03  1.731e-02  -0.516  0.61304
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.8818 on 16 degrees of freedom
Multiple R-squared:  0.9822,    Adjusted R-squared:  0.9545
F-statistic: 35.41 on 25 and 16 DF,  p-value: 8.055e-10
```

Podemos verificar que Autonomia, Cambio, Distância entre Eixos, Numero de Assentos, Tamanho do Pneu e Capacidade do porta-malas são estatisticamente relevantes ao nosso modelo.

As métricas mostram que com R^2 Ajustado de 95,45%, conseguimos afirmar que nosso modelo consegue explicar 95% da variabilidade do consumo médio, pelas variáveis que listamos.

Essa informação pode indicar que nosso modelo está com overfitting, ou seja, treinado demais e pouco generalizável. De qualquer forma, o intuito deste modelo era apenas identificar as variáveis mais importantes, o que nos serviu perfeitamente.

Uma observação importante que fizemos é que os dados estão em escalas diferentes e isso poderia alterar o resultado do modelo de identificação das variáveis mais importantes. Então refizemos o modelo com dados normalizados. Utilizamos uma função MinMax para deixar todas as variáveis na mesma escala.

```
# Aplicando Padronização ao Dataset

      # Criando um função de Padronizar

        padronizar <- function(x) {
          return ((x - min(x)) / (max(x) - min(x)))
        }

      # Primeiramente vamos dividir nosso modelo em dados de treino e teste.
```

```
  separador <- createDataPartition(y = dados$ConsMedio, p = 0.75,
                                   list = FALSE)
  dados_treino <- dados[separador,]
  dados_teste <- dados[-separador,]

  str(dados_teste)
  str(dados_treino)

# Aplicando a Função aos Dados Treino Numéricos


  dados_testeNumP <- dados_teste[,!unlist(lapply(dados_teste,
                                                 is.factor))]
  str(dados_testeNumP)

  dados_testeFac <- dados_teste[, unlist(lapply(dados_teste
                                                , is.factor))]
  str(dados_testeFac)

  dados_treinoNumP <- dados_treino[,!unlist(lapply(dados_treino,
                                                  is.factor))]
  str(dados_treinoNumP)

  dados_treinoFac <- dados_treino[, unlist(lapply(dados_treino
                                                , is.factor))]
  str(dados_treinoFac)

  dados_testeNumP <- as.data.frame(lapply(dados_testeNumP[,-18]
                                          , padronizar))
  dados_testeNumP <- cbind(dados_testeNumP, dados_teste$ConsMedio)
  colnames(dados_testeNumP)[18] <- 'ConsMedio'
  str(dados_testeNumP)

  dados_treinoNumP <- as.data.frame(lapply(dados_treinoNumP[, -18],
                                           padronizar))
  dados_treinoNumP <- cbind(dados_treinoNumP, dados_treino$ConsMedio)
  colnames(dados_treinoNumP)[18] <- 'ConsMedio'
  str(dados_treinoNumP)

# Unificando os Data Frames

  dados_treino_final <- cbind(dados_treinoNumP, dados_treinoFac)
  dados_teste_final <- cbind(dados_testeNumP, dados_testeFac)

  str(dados_treino_final)
  str(dados_teste_final)
```

```
# Reavaliando as Variáveis de Maior Significância

    dados_final <- rbind(dados_treino_final, dados_teste_final)
     FeaturesLMS <- lm(ConsMedio ~ ., data = dados_final)
     summary(FeaturesLMS)
```

```
Call:
lm(formula = ConsMedio ~ ., data = dados_final)

Residuals:
     Min       1Q   Median       3Q      Max
-0.95879 -0.33334 -0.01356  0.34427  1.05642

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)    16.6138     2.2395   7.419 1.46e-06 ***
PrecoMin        1.2369     4.2953   0.288 0.777061
Potencia        8.0887     5.1687   1.565 0.137158
TorqMax        -0.3851     2.7555  -0.140 0.890606
CapBat         10.4525     3.6385   2.873 0.011048 *
Autonomia      -7.5258     2.1371  -3.522 0.002832 **
DistEixos     -12.6267     4.5659  -2.765 0.013789 *
Comprimento     4.8813     4.8253   1.012 0.326780
Largura        -0.5382     1.0920  -0.493 0.628791
Altura          2.6975     2.7209   0.991 0.336245
PesoVazio       3.7471     8.2349   0.455 0.655199
PesoCheio      -4.0409     5.0726  -0.797 0.437338
CapMax          3.9142     1.7945   2.181 0.044432 *
TamPneu        -7.2467     1.7481  -4.145 0.000761 ***
VelMax        -10.6552     5.2359  -2.035 0.058761 .
BootCap         5.1904     2.7796   1.867 0.080280 .
Acc            -2.4776     2.4640  -1.006 0.329618
CapMaxBat       2.7448     3.0502   0.900 0.381527
Freios2        -1.2319     1.0308  -1.195 0.249484
Cambio2         3.1542     0.8691   3.629 0.002255 **
Cambio3         3.8343     1.6382   2.341 0.032540 *
NumAssentos4    5.0579     2.2070   2.292 0.035825 *
NumAssentos5    5.1798     2.6637   1.945 0.069624 .
NumAssentos8    9.4808     4.2587   2.226 0.040716 *
NumeroPortas4   1.2353     2.2536   0.548 0.591154
NumeroPortas5  -2.3233     1.3482  -1.723 0.104113
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.8516 on 16 degrees of freedom
Multiple R-squared:  0.9834,    Adjusted R-squared:  0.9576
F-statistic: 38.02 on 25 and 16 DF,  p-value: 4.666e-10
```

Temos então uma resposta semelhante de R^2 ajustado, mas com variáveis diferentes, sendo assim, vamos admitir as variáveis: CapBat, Autonomia, DistEixos, CapMax, Cambio e NumAssentos.

```
dados_prep_teste <- dados_teste_final %>% select(CapBat, Autonomia, DistEixos,
                                                 CapMax, Cambio, NumAssentos,
                                                 ConsMedio)
    str(dados_prep_teste)

    dados_prep_treino <- dados_treino_final %>% select(CapBat, Autonomia, DistEixos,
                                                   CapMax, Cambio, NumAssentos,
                                                   ConsMedio)
    str(dados_prep_treino)


    write.csv2(dados_prep_treino,file = 'dados/dados_prep_treino.csv')

    write.csv2(dados_prep_teste,file = 'dados/dados_prep_teste.csv')
```

Modelagem Preditiva

```
# Parte 04 - Modelagem Preditiva

  # Neste etapa, vamos criar modelos de machine learning e analisar as métricas
  # de cada modelo e definir qual realiza previsões com mais eficiência,
  # utilizando o dataset preparado e levando em consideração nosso modelo
  # preditivo base.
```

```
# Carregando Pacotes

  library(dplyr)
  library(caret)
  library(ggplot2)
  library(forecast)

# Carregando o Dataset

  dados_treino <- read.csv2('dados/dados_prep_treino.csv', header = TRUE)[-1]
  str(dados_treino)
  dados_teste <- read.csv2('dados/dados_prep_teste.csv', header = TRUE)[-1]
  str(dados_teste)

  summary(is.na(dados_treino))
  summary(is.na(dados_teste))
```

Construindo o Modelo Base e Analisando o Resultado

Modelo Base

Vamos construir o modelo base com a função lm() do pacote utils base da linguagem R.

```
# Construindo nosso Modelo Base

      # Vamos utilizar a função lm() para construir nosso modelo base, sendo o
      # algoritmo mais simples que conhecemos.

      ModeloBase <- lm(ConsMedio ~ ., dados_treino)
      summary(ModeloBase)

        # Nosso modelo Base possui em treinamento, um R² de 92,67% ajustado, o
        # que siginifica que conseguimos explicar o consumo com 92,67% de
        # variabilidade dessas variáveis.

      # Acurácia do Modelo Base de Treino
        prev_treino_ModeloB <- predict(ModeloBase, dados_treino[-8])
        accuracy(prev_treino_ModeloB, dados_treino$ConsMedio)

          # Acurácia de RMSE 1.407
```

```
Call:
lm(formula = ConsMedio ~ ., data = dados_treino)

Residuals:
    Min      1Q  Median      3Q     Max
-3.3493 -0.7016  0.0883  0.5107  2.4363

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  14.0363     1.9469   7.209 1.17e-07 ***
CapBat       17.6938     2.1127   8.375 7.41e-09 ***
Autonomia   -14.1841     1.6552  -8.570 4.76e-09 ***
DistEixos    -3.8796     4.1306  -0.939  0.35626
CapMax        6.8222     2.0469   3.333  0.00259 **
Cambio        0.7917     0.4980   1.590  0.12399
NumAssentos   0.2588     0.5429   0.477  0.63760
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.157 on 26 degrees of freedom
Multiple R-squared:  0.9404,    Adjusted R-squared:  0.9267
F-statistic: 68.41 on 6 and 26 DF,  p-value: 1.114e-14
```

Nosso modelo base possui em treinamento, um R^2 de 92,67% ajustado, o que significa que conseguimos explicar o consumo médio com 92% de variabilidade das variáveis independentes. Um valor bom para a métrica, assim como a acurácia do modelo de treino base com um RMSE de 1.027.

```
>         accuracy(prev_treino_ModeloB, dados_treino$ConsMedio)
                     ME     RMSE       MAE         MPE     MAPE
Test set 2.691476e-15 1.027163 0.7549713 -0.3647261 4.476753
```

Vamos realizar as previsões dos dados de teste e analisar os resíduos.

```
# Testando e Avaliando o Modelo

      Previsao01 <- predict(ModeloBase, dados_teste[-8])
      Previsao01

      # Analisando a Acurárcia do Teste para o Modelo Base

        accuracy(Previsao01, dados_teste$ConsMedio)

          # Obtivemos uma acurácia relativamente mais alta que em treino
          # no valor de RMSE 2.907. !! Ponto de Atenção

      # Analisando o resíduo do modelo

        ConsumoTeste <- dados_teste$ConsMedio

        Res_ModeloBase <- ConsumoTeste - Previsao01

        FitModeloBase <- data.frame(Target = ConsumoTeste,
                                    Previsao = Previsao01,
                                    Residuo = Res_ModeloBase)
        head(FitModeloBase)
        summary(FitModeloBase)

      # Scatter Plot Comparativo

        camada1 <- geom_point(shape = 1)

        camada2 <- geom_smooth(method = lm, color = 'red', se = FALSE)

        ggplot(FitModeloBase, aes(x = Previsao, y = Target)) + camada1 + camada2 +
          ggtitle('Performance do Modelo Base') + annotate(geom = 'text', x = 17,
                                                           y = 25,
                                                           label = 'R² = 92,67 RSME = 2,22%')
```

Podemos ver que temos uma média nos resíduos próximo a zero e um range pequeno entre os valores mínimos e máximos. Vamos ver a regressão graficamente.

Consequentemente temos uma ótima acurácia e poucos erros em relação aos resulados medidos no teste.

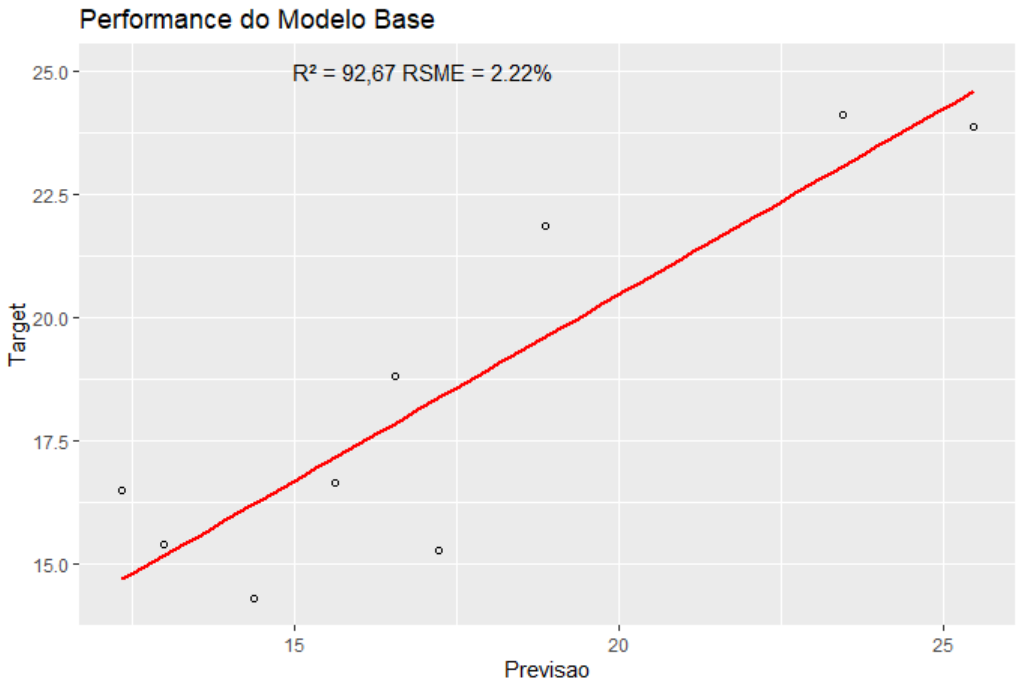


```
>         head(FitModeloBase)
  Target Previsao     Residuo
1  23.85 25.46181 -1.61180984
2  14.30 14.36639 -0.06639241
3  18.80 16.56364  2.23636045
4  15.40 12.98300  2.41699755
5  15.30 17.23469 -1.93468759
6  21.85 18.87666  2.97333844
```

```
>         summary(FitModeloBase)
     Target         Previsao        Residuo        
 Min.   :14.30   Min.   :12.35   Min.   :-1.93469  
 1st Qu.:15.40   1st Qu.:14.37   1st Qu.:-0.06639  
 Median :16.65   Median :16.56   Median : 1.01638  
 Mean   :18.53   Mean   :17.43   Mean   : 1.09301  
 3rd Qu.:21.85   3rd Qu.:18.88   3rd Qu.: 2.41700  
 Max.   :24.10   Max.   :25.46   Max.   : 4.15171  
```

Modelo V02

Para o modelo V02 vamos trocar o algoritmo mas manter o método de regressão. Vamos utilizar o Caret com o método ‘lm’.

```
# Construindo Modelo Versão 02

# Para este modelo, utilizaremo o pacote Caret com o método de Regressão
# Linear, sem Trainig Control e Tuning.

  ModeloV02 <- train(ConsMedio ~ ., data = dados_treino, method = 'lm')
  summary(ModeloV02)

# Podemos reparar que obtivemos um R² de 92,67%, mesmo valor do modelo base.
# Vamos realizar a Previsão de teste e avaliar
# graficamente.

  Previsao02 <- predict(ModeloV02, dados_teste[-8])
  Previsao02

  accuracy(Previsao02, dados_teste$ConsMedio)

    # Mesma acurácia do modelo base RMSE 2.907

  # Analisando o resíduo do modelo

  Res_ModeloV02 <- ConsumoTeste - Previsao02

  FitModeloV02 <- data.frame(Target = ConsumoTeste,
                             Previsao = Previsao02,
                             Residuo = Res_ModeloV02)
  head(FitModeloV02)
```

```
summary(FitModeloV02)

# Scatter Plot Comparativo

camada1 <- geom_point(shape = 1)

camada2 <- geom_smooth(method = lm, color = 'red', se = FALSE)

ggplot(FitModeloV02, aes(x = Previsao, y = Target)) + camada1 + camada2 +
  ggtitle('Performance do Modelo V02') + annotate(geom = 'text', x = 17,
                                                  y = 25,
                                                  label = 'R² = 92,67 RSME = 2.22%')
```

```
Call:
lm(formula = .outcome ~ ., data = dat)

Residuals:
    Min      1Q  Median      3Q     Max
-3.3493 -0.7016  0.0883  0.5107  2.4363

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  14.0363     1.9469   7.209 1.17e-07 ***
CapBat       17.6938     2.1127   8.375 7.41e-09 ***
Autonomia   -14.1841     1.6552  -8.570 4.76e-09 ***
DistEixos    -3.8796     4.1306  -0.939  0.35626
CapMax        6.8222     2.0469   3.333  0.00259 **
Cambio        0.7917     0.4980   1.590  0.12399
NumAssentos   0.2588     0.5429   0.477  0.63760
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 1.157 on 26 degrees of freedom
Multiple R-squared:  0.9404,    Adjusted R-squared:  0.9267
F-statistic: 68.41 on 6 and 26 DF,  p-value: 1.114e-14
```

Perceba que apenas alterando o pacote, não tivemos qualquer diferença entre os resultados.

```
>     accuracy(Previsao02, dados_teste$ConsMedio)
                ME     RMSE      MAE      MPE     MAPE
Test set 1.093011 2.229308 1.895876 6.146204 10.56118
```

```
>     head(FitModeloV02)
  Target Previsao     Residuo
1  23.85 25.46181 -1.61180984
2  14.30 14.36639 -0.06639241
3  18.80 16.56364  2.23636045
4  15.40 12.98300  2.41699755
5  15.30 17.23469 -1.93468759
6  21.85 18.87666  2.97333844
```

```
     Target         Previsao        Residuo
 Min.   :14.30   Min.   :12.35   Min.   :-1.93469
 1st Qu.:15.40   1st Qu.:14.37   1st Qu.:-0.06639
 Median :16.65   Median :16.56   Median : 1.01638
 Mean   :18.53   Mean   :17.43   Mean   : 1.09301
 3rd Qu.:21.85   3rd Qu.:18.88   3rd Qu.: 2.41700
 Max.   :24.10   Max.   :25.46   Max.   : 4.15171
```

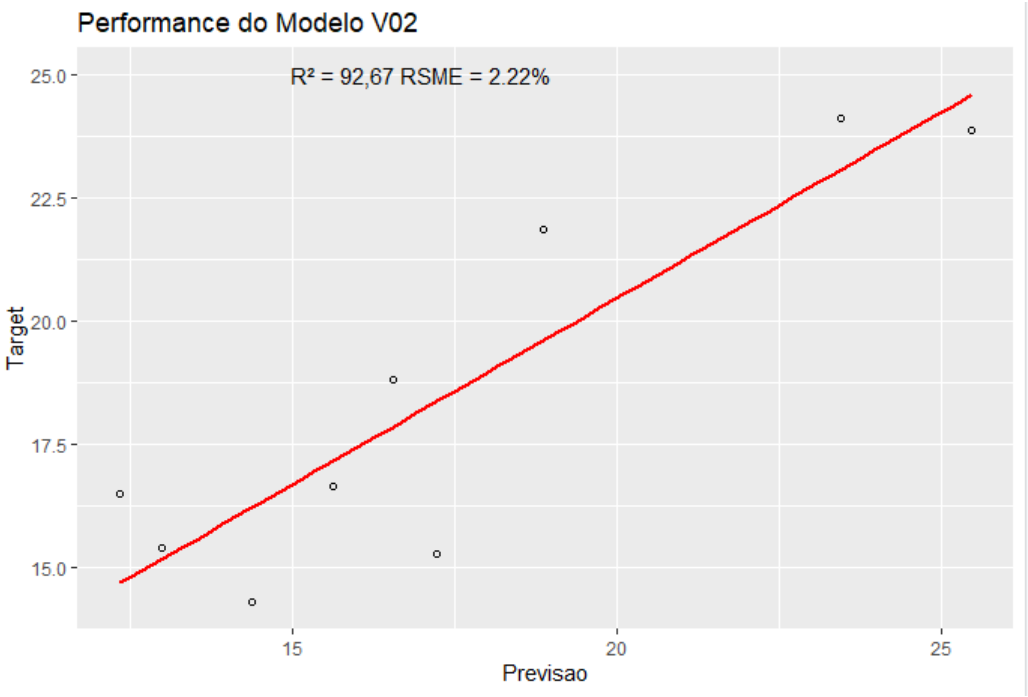

Modelo V03

Para este modelo vamos mudar o método de regressão linear para o Método Boosted Linear Regression.

```
  # Construindo Modelo V03

# Para este modelo vamos alterar o método de Regressão Linear para Boosted
# Linear Regression e analisar os resultados.
# Utilizaremos o mesmo pacote Caret.


    ModeloV03 <- train(ConsMedio ~ ., data = dados_treino, method = 'BstLm')
    ModeloV03

    Previsao03 <- predict(ModeloV03, dados_teste[-8])
    Previsao03

    # Acurácia de RMSE 3.34 e um R² de 65.12%, obtendo uma performance
    # inferior em R² e acurácia

    # Analisando o resíduo do modelo

    Res_ModeloV03 <- ConsumoTeste - Previsao03

    FitModeloV03 <- data.frame(Target = ConsumoTeste,
                               Previsao = Previsao03,
                               Residuo = Res_ModeloV03)
    head(FitModeloV03)
    summary(FitModeloV03)

    # Scatter Plot Comparativo

    ggplot(FitModeloV03, aes(x = Previsao, y = Target)) +
      geom_point(shape = 1) +
      geom_smooth(method = lm, color = 'red', se = FALSE) +
      ggtitle('Performance do Modelo V03')+
      annotate(geom = 'text', x = 17, y = 25, label = 'R² = 65,12% RSME = 3.34')
```

```
>       ModeloV03
Boosted Linear Model

33 samples
 6 predictor

No pre-processing
Resampling: Bootstrapped (25 reps)
Summary of sample sizes: 33, 33, 33, 33, 33, 33, ...
Resampling results across tuning parameters:

  mstop  RMSE      Rsquared   MAE
   50    3.833294  0.5773610  3.431336
  100    3.566225  0.6157972  3.111424
  150    3.341078  0.6512431  2.854399

Tuning parameter 'nu' was held constant at a value of 0.1
RMSE was used to select the optimal model using the
 smallest value.
The final values used for the model were mstop = 150 and nu
 = 0.1.
```

	Target	Previsao	Residuo
1	23.85	23.43588	0.4141222
2	14.30	17.16161	-2.8616109
3	18.80	20.10335	-1.3033470
4	15.40	17.96319	-2.5631871
5	15.30	17.78603	-2.4860301
6	21.85	19.54537	2.3046302

Target	Previsao	Residuo
Min. :14.30	Min. :16.65	Min. :-2.8616
1st Qu.:15.40	1st Qu.:17.16	1st Qu.:-2.4860
Median :16.65	Median :17.96	Median :-0.2657
Mean :18.53	Mean :19.20	Mean :-0.6733
3rd Qu.:21.85	3rd Qu.:20.10	3rd Qu.: 0.4141
Max. :24.10	Max. :23.44	Max. : 2.3046

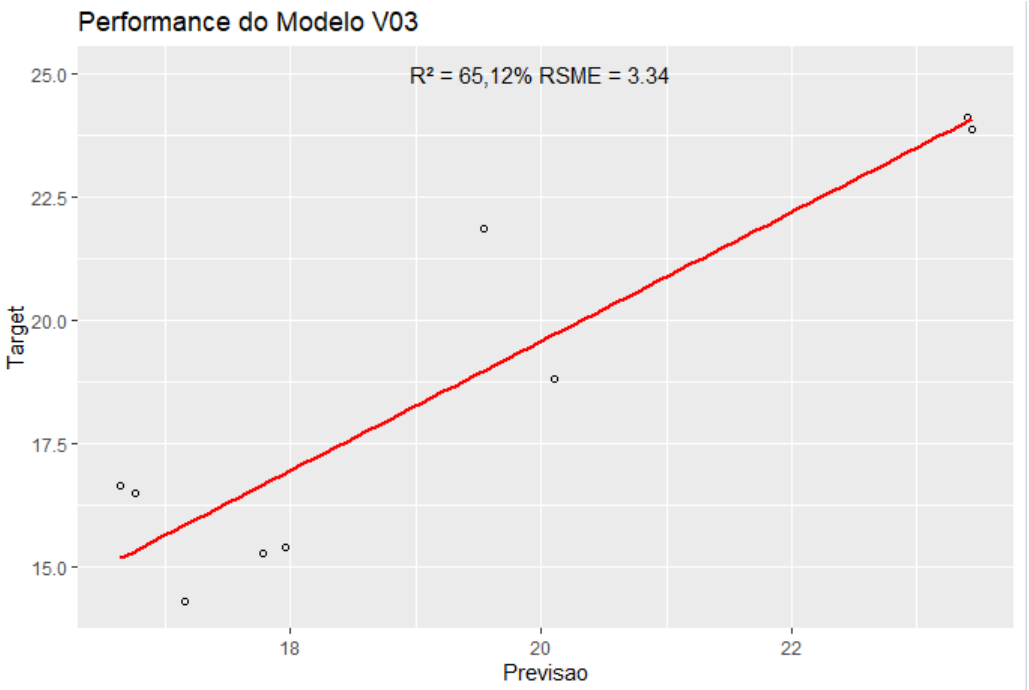

Neste modelo tivemos um R^2 de 65,12% aproximadamente, com 25 repetições de re-amostragem. Neste método, realizamos diversas iteracões com amostragens menores do dataset e identificamos a que possui menor RMSE e consequentemente maior R^2. De qualquer forma tivemos um resultao pior que em nosso Modelo Base.

Modelo V04

Para este modelo usaremos outro método do pacote Caret, chamado de glmnet.

```
# Contruindo Modelo V04

    # Para este modelo vamos alterar o método de Regressão Linear para glmnet
    # e analisar os resultados.
    # Utilizaremos o mesmo pacote Caret.

      ModeloV04 <- train(ConsMedio ~ ., data = dados_treino, method = 'glmnet')
      ModeloV04

      # Tivemos uma piora drástica do R² em relação ao Modelo V03, porém ainda
      # assim nosso modelo base é melhor em relação a métrica de varibilidade
      # das variáveis em relação a variável resposta.

      Previsao04 <- predict(ModeloV04, dados_teste[-8])
      Previsao04

      # Analisando o resíduo do modelo

      Res_ModeloV04 <- ConsumoTeste - Previsao04

      FitModeloV04 <- data.frame(Target = ConsumoTeste,
                                 Previsao = Previsao04,
                                 Residuo = Res_ModeloV04)
      head(FitModeloV03)
      summary(FitModeloV04)

      # Scatter Plot Comparativo

      ggplot(FitModeloV04, aes(x = Previsao, y = Target)) +
        geom_point(shape = 1) +
        geom_smooth(method = lm, color = 'red', se = FALSE) +
        ggtitle('Performance do Modelo V04')+
        annotate(geom = 'text', x = 17, y = 25, label = 'R² = 77,77%')
```

```
>       ModeloV04
glmnet

33 samples
 6 predictor

No pre-processing
Resampling: Bootstrapped (25 reps)
Summary of sample sizes: 33, 33, 33, 33, 33, 33, ...
Resampling results across tuning parameters:

  alpha  lambda       RMSE      Rsquared   MAE
  0.10   0.006295296  1.664000  0.8439565  1.236413
  0.10   0.062952965  1.704398  0.8422168  1.290303
  0.10   0.629529645  2.169265  0.7640937  1.710190
  0.55   0.006295296  1.660722  0.8450119  1.232211
  0.55   0.062952965  1.687921  0.8464261  1.276365
  0.55   0.629529645  2.483541  0.6968285  1.942585
  1.00   0.006295296  1.656760  0.8460774  1.228075
  1.00   0.062952965  1.686541  0.8458511  1.275791
  1.00   0.629529645  2.813177  0.6168897  2.166624

RMSE was used to select the optimal model using the
 smallest value.
The final values used for the model were alpha = 1 and lambda
 = 0.006295296.
```

```
  Target Previsao    Residuo
1  23.85 23.43588  0.4141222
2  14.30 17.16161 -2.8616109
3  18.80 20.10335 -1.3033470
4  15.40 17.96319 -2.5631871
5  15.30 17.78603 -2.4860301
6  21.85 19.54537  2.3046302
```

```
    Target         Previsao        Residuo
Min.   :14.30   Min.   :12.00   Min.   :-1.8369
1st Qu.:15.40   1st Qu.:14.05   1st Qu.: 0.2538
Median :16.65   Median :16.73   Median : 1.5001
Mean   :18.53   Mean   :17.32   Mean   : 1.2085
3rd Qu.:21.85   3rd Qu.:19.07   3rd Qu.: 2.7768
Max.   :24.10   Max.   :25.55   Max.   : 4.5012
```

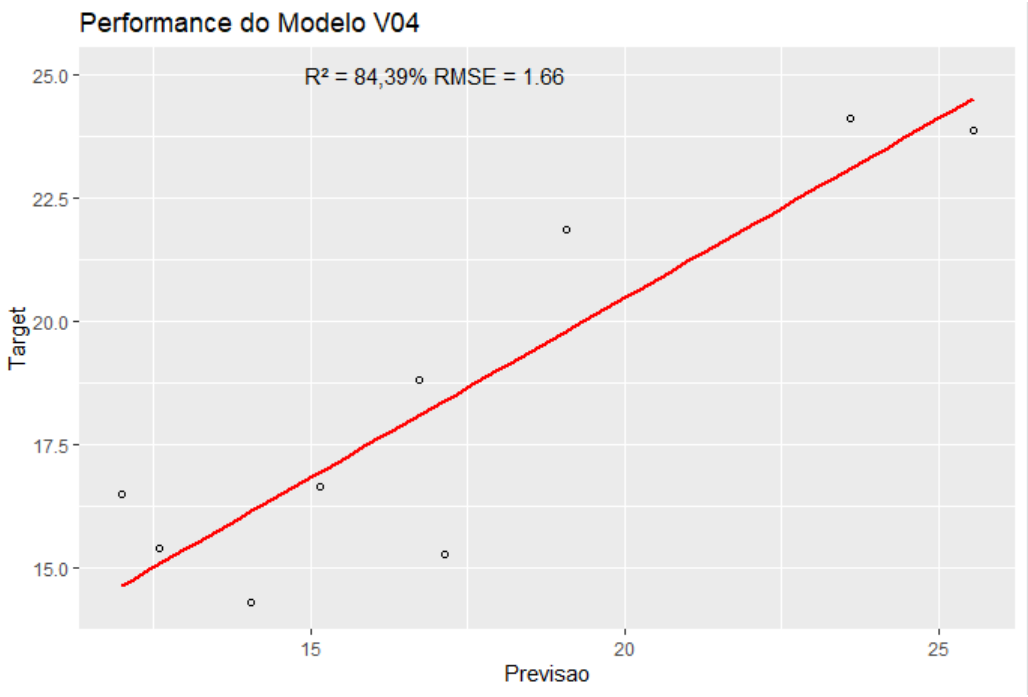

Atingimos aqui 84,39% de R^2, uma melhora drástica em relação ao modelo V03, porém ainda menor que nosso modelo base, porém uma acurácia melhor de 1.66.

Conclusão

Portanto finalizamos nosso trabalho, disponibilizando o Modelo V04 como apto a realizar novas previsões para a área de negócio, pois apresenta melhor performance nas métricas e nos resíduos gerados.

Importante ressaltar que os novos dados a serem aplicados as variáveis do modelo, necessariamente precisam ser tratados da mesma forma que fizemos durante o processo de pre-processamento. Ou seja, sem outliers, sem dados NaN e normalizados para que possam ter a mesma escala de valor.

Concluimos o projeto com este relatório, incluindo a descrição do script realizado em linguagem R.